

# Analysis Prediction

## Documentación de uso y configuración

---

Referencia funcional del pipeline de ingestión, calidad de datos, integración, análisis exploratorio, feature engineering, modelado temporal y predicción operativa de demanda por artículo

|                               |                                                                                           |
|-------------------------------|-------------------------------------------------------------------------------------------|
| <b>Versión del documento:</b> | 1.0                                                                                       |
| <b>Fecha:</b>                 | 13 de septiembre de 2026                                                                  |
| <b>Punto de entrada:</b>      | <code>analysis_prediction.py</code>                                                       |
| <b>Lenguaje:</b>              | Python                                                                                    |
| <b>Autores:</b>               | Joaquín Delgado Amar<br>Cándida Oviedo Martí<br>Laura Simón Revuelta<br>Ana Ruiz Martínez |

Esta documentación describe la interfaz de uso, los parámetros de configuración, los artefactos generados y las decisiones metodológicas relevantes del código distribuido con el proyecto.

# Control del documento

|                           |                                                                          |
|---------------------------|--------------------------------------------------------------------------|
| <b>Documento</b>          | Documentación de uso y configuración de <code>analysis_prediction</code> |
| <b>Versión</b>            | 1.0                                                                      |
| <b>Fecha</b>              | 13 de septiembre de 2026                                                 |
| <b>Ámbito</b>             | Pipeline de predicción de demanda por artículo                           |
| <b>Interfaz principal</b> | <code>analysis_prediction.py</code>                                      |
| <b>Configuración</b>      | Flags de ejecución y objetos <code>*Rules</code>                         |
| <b>Salidas</b>            | Parquet, CSV, JSON y PNG bajo <code>data/</code> y <code>results/</code> |

## Alcance

El documento está concebido como referencia oficial de operación y configuración. Describe la interfaz pública del pipeline y el significado de sus principales parámetros. No pretende sustituir la documentación interna de cada función ni explicar la implementación línea a línea.

# Índice general

|                                                              |           |
|--------------------------------------------------------------|-----------|
| <b>Control del documento</b>                                 | <b>1</b>  |
| <b>1. Descripción general del sistema</b>                    | <b>6</b>  |
| 1.1. Finalidad . . . . .                                     | 6         |
| 1.2. Arquitectura . . . . .                                  | 6         |
| 1.3. Módulos . . . . .                                       | 7         |
| <b>2. Instalación y puesta en marcha</b>                     | <b>8</b>  |
| 2.1. Requisitos . . . . .                                    | 8         |
| 2.2. Estructura de directorios . . . . .                     | 8         |
| 2.3. Ejecución . . . . .                                     | 9         |
| <b>3. Flags de ejecución</b>                                 | <b>10</b> |
| 3.1. Referencia rápida . . . . .                             | 10        |
| 3.2. DO_INGEST . . . . .                                     | 10        |
| 3.3. DO_DEPURATION . . . . .                                 | 10        |
| 3.4. DO_EDA . . . . .                                        | 11        |
| 3.5. DO_FEATURES . . . . .                                   | 11        |
| 3.6. DO_MODELING . . . . .                                   | 11        |
| 3.7. DO_OPERATIONAL . . . . .                                | 11        |
| 3.8. Combinaciones de uso . . . . .                          | 11        |
| 3.9. Validaciones de coherencia . . . . .                    | 12        |
| <b>4. Fuentes, rutas y opciones generales</b>                | <b>13</b> |
| 4.1. Rutas principales . . . . .                             | 13        |
| 4.2. Entradas estructuradas . . . . .                        | 13        |
| 4.3. Opciones generales . . . . .                            | 13        |
| <b>5. Ingestión y capa Bronze</b>                            | <b>15</b> |
| 5.1. Responsabilidad . . . . .                               | 15        |
| 5.2. Outputs . . . . .                                       | 15        |
| 5.3. Nivel de detalle de consola . . . . .                   | 15        |
| <b>6. Depuración y calidad de datos</b>                      | <b>16</b> |
| 6.1. Principios . . . . .                                    | 16        |
| 6.2. Configuración de <code>DepurationRules</code> . . . . . | 16        |
| 6.3. Cómo modificar la política de missing values . . . . .  | 17        |
| 6.4. Cómo modificar la detección de outliers . . . . .       | 18        |
| 6.5. Outputs Silver . . . . .                                | 18        |
| 6.6. Informes de calidad . . . . .                           | 18        |

|                                                                  |           |
|------------------------------------------------------------------|-----------|
| 6.7. Figuras de calidad . . . . .                                | 19        |
| <b>7. Integración y capa Gold</b>                                | <b>20</b> |
| 7.1. Objetivo . . . . .                                          | 20        |
| 7.2. Configuración de <code>IntegrationRules</code> . . . . .    | 20        |
| 7.3. Informes . . . . .                                          | 21        |
| <b>8. Análisis exploratorio de datos</b>                         | <b>22</b> |
| 8.1. Configuración . . . . .                                     | 22        |
| 8.2. Tablas EDA . . . . .                                        | 22        |
| 8.3. Figuras EDA . . . . .                                       | 23        |
| <b>9. Ingeniería de variables</b>                                | <b>25</b> |
| 9.1. Objetivo . . . . .                                          | 25        |
| 9.2. Configuración de <code>FeatureRules</code> . . . . .        | 25        |
| 9.3. Régimen histórico de demanda . . . . .                      | 26        |
| 9.4. Catálogo de variables . . . . .                             | 26        |
| <b>10. Selección de variables para modelado</b>                  | <b>28</b> |
| 10.1. Proceso . . . . .                                          | 28        |
| 10.1.1. Nivel 1: seguridad temporal . . . . .                    | 28        |
| 10.1.2. Nivel 2: calidad dentro de Development . . . . .         | 28        |
| 10.2. Tratamiento de variables numéricas y categóricas . . . . . | 28        |
| 10.3. Auditoría de la selección . . . . .                        | 29        |
| <b>11. Modelos implementados y validación</b>                    | <b>30</b> |
| 11.1. Target . . . . .                                           | 30        |
| 11.2. Separación temporal . . . . .                              | 30        |
| 11.3. Baselines causales . . . . .                               | 31        |
| 11.4. <code>HistGradientBoosting Poisson</code> . . . . .        | 31        |
| 11.5. Random Forest . . . . .                                    | 31        |
| 11.6. Selector adaptativo por régimen . . . . .                  | 32        |
| 11.7. Métricas . . . . .                                         | 32        |
| 11.8. Apertura del holdout final . . . . .                       | 32        |
| <b>12. Outputs del modelado</b>                                  | <b>34</b> |
| 12.1. Tablas de modelado . . . . .                               | 34        |
| 12.2. Predicciones de evaluación . . . . .                       | 35        |
| 12.3. Informe JSON . . . . .                                     | 35        |
| <b>13. Contexto futuro</b>                                       | <b>36</b> |
| 13.1. Información admitida . . . . .                             | 36        |
| 13.2. Configuración . . . . .                                    | 36        |
| 13.3. Outputs . . . . .                                          | 36        |
| <b>14. Universo de artículos</b>                                 | <b>37</b> |
| 14.1. Objetivo . . . . .                                         | 37        |
| 14.2. Políticas . . . . .                                        | 37        |
| 14.3. Parámetros principales . . . . .                           | 37        |
| 14.4. Outputs . . . . .                                          | 38        |

|                                                                   |           |
|-------------------------------------------------------------------|-----------|
| <b>15.Forecast operacional</b>                                    | <b>39</b> |
| 15.1. Proceso de despliegue . . . . .                             | 39        |
| 15.2. Configuración . . . . .                                     | 39        |
| 15.3. Outputs . . . . .                                           | 40        |
| 15.4. Columnas principales del forecast . . . . .                 | 40        |
| <b>16.Catálogo global de outputs</b>                              | <b>42</b> |
| 16.1. Dónde consultar cada tipo de resultado . . . . .            | 42        |
| <b>17.Procedimientos de uso</b>                                   | <b>44</b> |
| 17.1. Reconstrucción completa . . . . .                           | 44        |
| 17.2. Recalcular únicamente el EDA . . . . .                      | 44        |
| 17.3. Rehacer Features, modelado y forecast . . . . .             | 44        |
| 17.4. Repetir el experimento de modelado . . . . .                | 44        |
| 17.5. Generar solo el siguiente forecast . . . . .                | 45        |
| <b>18.Personalización controlada</b>                              | <b>46</b> |
| 18.1. Cambiar criterios de depuración . . . . .                   | 46        |
| 18.1.1. Aumentar el umbral de imputación . . . . .                | 46        |
| 18.1.2. No imputar variables numéricas . . . . .                  | 46        |
| 18.1.3. Hacer más conservadora la detección de outliers . . . . . | 46        |
| 18.1.4. Eliminar outliers . . . . .                               | 46        |
| 18.2. Cambiar lags y ventanas . . . . .                           | 46        |
| 18.3. Cambiar el holdout o CV . . . . .                           | 47        |
| 18.4. Cambiar hiperparámetros . . . . .                           | 47        |
| 18.5. Cambiar la política de scope . . . . .                      | 47        |
| <b>19.Interpretación de warnings y problemas frecuentes</b>       | <b>48</b> |
| 19.1. Periodo histórico incompleto . . . . .                      | 48        |
| 19.2. Sin previsión meteorológica . . . . .                       | 48        |
| 19.3. Muchos outliers . . . . .                                   | 48        |
| 19.4. Falta una capa persistida . . . . .                         | 48        |
| <b>20.Reproducibilidad y trazabilidad</b>                         | <b>49</b> |
| 20.1. Principios . . . . .                                        | 49        |
| 20.2. Artefactos mínimos para auditar una ejecución . . . . .     | 49        |
| <b>A. Referencia rápida de configuración</b>                      | <b>50</b> |
| A.1. Configuración estándar . . . . .                             | 50        |
| A.2. Checklist previo a una ejecución completa . . . . .          | 50        |
| A.3. Orden recomendado de consulta de resultados . . . . .        | 51        |
| <b>B. Resumen de interfaz pública</b>                             | <b>52</b> |

# Índice de cuadros

|                                                                    |    |
|--------------------------------------------------------------------|----|
| 1.1. Módulos principales del proyecto. . . . .                     | 7  |
| 3.1. Flags principales de ejecución. . . . .                       | 10 |
| 3.2. Configuraciones de ejecución recomendadas. . . . .            | 12 |
| 4.1. Opciones generales de ejecución. . . . .                      | 14 |
| 6.1. Parámetros de depuración configurables. . . . .               | 16 |
| 6.2. Artefactos de calidad por dataset. . . . .                    | 19 |
| 6.3. Figuras de depuración. . . . .                                | 19 |
| 7.1. Parámetros de integración. . . . .                            | 20 |
| 7.2. Informes de integración. . . . .                              | 21 |
| 8.1. Parámetros principales del EDA. . . . .                       | 22 |
| 8.2. Tablas generadas por el EDA. . . . .                          | 23 |
| 8.3. Figuras principales del EDA. . . . .                          | 23 |
| 9.1. Parámetros de ingeniería de variables. . . . .                | 25 |
| 11.1. Configuración temporal del modelado. . . . .                 | 30 |
| 12.1. Tablas persistidas por <code>ap_modeling.py</code> . . . . . | 34 |
| 12.2. Predicciones persistidas durante la evaluación. . . . .      | 35 |
| 14.1. Configuración del scope de artículos. . . . .                | 37 |
| 15.1. Parámetros operacionales. . . . .                            | 39 |
| 15.2. Outputs operacionales. . . . .                               | 40 |
| 15.3. Campos principales de la salida operacional. . . . .         | 40 |
| 16.1. Mapa de resultados del repositorio. . . . .                  | 42 |

# 1. Descripción general del sistema

## 1.1 Finalidad

`analysis_prediction` es un pipeline modular para transformar fuentes operativas heterogéneas de un negocio hostelero en una previsión de demanda por artículo para el siguiente periodo de reporte.

El objetivo operativo del módulo de predicción es estimar:

$$\hat{y}_{i,t+1} = \text{unidades previstas del artículo } i \text{ en el siguiente periodo}$$

El sistema incorpora procesos de calidad de datos, trazabilidad, validación temporal, comparación de modelos, selección adaptativa y preparación de una salida orientada a planificación.

## 1.2 Arquitectura

La arquitectura implementa una secuencia de capas persistentes:

```
Raw
|
v
Ingestion
|
v
Bronze
|
v
Depuration
|
v
Silver
|
v
Integration
|
v
Gold
|
v
EDA
|
v
```

```

Feature engineering
|
v
Temporal modeling
|
v
Future context
|
v
Article scope
|
v
Operational forecast

```

La persistencia intermedia permite ejecutar el pipeline completo o reutilizar capas ya generadas.

## 1.3 Módulos

Cuadro 1.1: Módulos principales del proyecto.

| Módulo               | Responsabilidad                                                                  |
|----------------------|----------------------------------------------------------------------------------|
| ap_config.py         | Construcción y validación de la configuración global, rutas y reglas.            |
| ap_pipeline.py       | Orquestación de las etapas y reutilización de artefactos persistentes.           |
| ap_io.py             | Lectura de fuentes originales, normalización técnica y escritura Bronze.         |
| ap_depuration.py     | Calidad de datos, imputación conservadora, flags y detección de outliers.        |
| ap_integration.py    | Integración de Silver y construcción de las tablas maestras Gold.                |
| ap_eda.py            | Análisis exploratorio, tablas diagnósticas y visualizaciones.                    |
| ap_features.py       | Generación de variables temporales y catálogo de disponibilidad/leakage.         |
| ap_modeling.py       | Validación temporal, baselines, modelos de IA, selector adaptativo y holdout.    |
| ap_future_context.py | Construcción del contexto futuro conocido antes del horizonte de predicción.     |
| ap_article_scope.py  | Auditoría del universo de artículos elegibles para forecast.                     |
| ap_operational.py    | Refit de despliegue, predicción del siguiente periodo y clasificación operativa. |



## 2. Instalación y puesta en marcha

### 2.1 Requisitos

Se recomienda Python en un entorno virtual aislado.

En Windows PowerShell:

```
python -m venv .venv
.\.venv\Scripts\Activate.ps1
python -m pip install --upgrade pip
pip install -r requirements.txt
```

En Linux/macOS:

```
python -m venv .venv
source .venv/bin/activate
python -m pip install --upgrade pip
pip install -r requirements.txt
```

### 2.2 Estructura de directorios

```
analysis_prediction/
|
|-- analysis_prediction.py
|-- requirements.txt
|-- README.md
|
|-- src/
|   |-- ap_config.py
|   |-- ap_pipeline.py
|   |-- ap_io.py
|   |-- ap_depuration.py
|   |-- ap_integration.py
|   |-- ap_eda.py
|   |-- ap_features.py
|   |-- ap_modeling.py
|   |-- ap_future_context.py
|   |-- ap_article_scope.py
|   '-- ap_operational.py
|
|-- data/
|   |-- raw/
|       |-- ventas_semanal/
```

```
| | '-- pdfs/
| |-- bronze/
| |-- silver/
| |-- gold/
| '-- features/
|
|-- results/
    |-- depuration_figures/
    |-- depuration_reports/
    |-- integration_reports/
    |-- eda_figures/
    |-- eda_tables/
    |-- eda_reports/
    |-- feature_reports/
    |-- modeling_tables/
    |-- modeling_reports/
    |-- modeling_predictions/
    |-- future_context_tables/
    |-- future_context_reports/
    |-- article_scope_tables/
    |-- article_scope_reports/
    |-- operational_forecasts/
    '-- operational_reports/
```

## 2.3 Ejecución

El punto de entrada es:

```
python analysis_prediction.py
```

La configuración de usuario se concentra en la parte superior de `analysis_prediction.py`. La ejecución estándar no requiere modificar los módulos de `src/`.

## 3. Flags de ejecución

### 3.1 Referencia rápida

Los seis flags principales determinan qué etapas se recalculan.

Cuadro 3.1: Flags principales de ejecución.

| Flag           | Valores    | Efecto                                                                                                      |
|----------------|------------|-------------------------------------------------------------------------------------------------------------|
| DO_INGEST      | True/False | Lee las fuentes originales y genera la capa Bronze.                                                         |
| DO_DEPURATION  | True/False | Genera Silver y, en la misma etapa de ejecución, reconstruye Gold mediante integración.                     |
| DO_EDA         | True/False | Ejecuta análisis exploratorio sobre Silver/Gold y actualiza sus informes y figuras.                         |
| DO_FEATURES    | True/False | Reconstruye las tablas de Features y el catálogo de disponibilidad temporal.                                |
| DO_MODELING    | True/False | Ejecuta la evaluación temporal, los modelos candidatos, el selector adaptativo y los artefactos congelados. |
| DO_OPERATIONAL | True/False | Construye contexto futuro, audita el scope de artículos y genera el forecast del siguiente periodo.         |

### 3.2 DO\_INGEST

```
DO_INGEST = True
```

Con **True**, se procesan las fuentes de **data/raw/** y se actualiza **data/bronze/**. Debe activarse si han cambiado los ficheros originales, su contenido o el proceso de ingestión.

Con **False**, la ingestión se omite. Si posteriormente se solicita depuración, la procedencia se decide mediante **SOURCE\_WHEN\_INGEST\_DISABLED**.

### 3.3 DO\_DEPURATION

```
DO_DEPURATION = True
```

Reconstruye Silver a partir de Bronze o de entradas estructuradas y, a continuación, reconstruye Gold. Por tanto, no es un flag exclusivamente de limpieza: controla el bloque Bronze/Structured → Silver → Gold.

### 3.4 DO\_EDA

```
DO_EDA = True
```

Actualiza las tablas y figuras de análisis exploratorio. Puede desactivarse cuando se quieren ejecutar únicamente las etapas predictivas y el EDA ya ha sido generado.

### 3.5 DO\_FEATURES

```
DO_FEATURES = True
```

Regenera las matrices de variables predictivas a partir de Gold. Debe activarse si han cambiado los datos Gold o las reglas de ingeniería de variables.

### 3.6 DO\_MODELING

```
DO_MODELING = True
```

Regenera todo el experimento temporal de modelado y los artefactos que posteriormente utiliza la etapa operacional.

### 3.7 DO\_OPERATIONAL

```
DO_OPERATIONAL = True
```

Genera el forecast para el siguiente periodo utilizable, incluyendo:

- inferencia de la cadencia de reporte;
- contexto futuro conocido;
- auditoría del universo de artículos;
- refit de despliegue con histórico elegible;
- selección de modelo según el mapping congelado;
- predicciones por artículo;
- ranking y clasificación ABC.

### 3.8 Combinaciones de uso

Cuadro 3.2: Configuraciones de ejecución recomendadas.

| ING | DEP | EDA | FEAT | MOD | OP | Uso                                                             |
|-----|-----|-----|------|-----|----|-----------------------------------------------------------------|
| T   | T   | T   | T    | T   | T  | Reconstrucción completa desde Raw.                              |
| T   | F   | F   | F    | F   | F  | Actualizar únicamente Bronze.                                   |
| F   | T   | T   | T    | T   | T  | Reprocesar desde Bronze hasta forecast.                         |
| F   | F   | T   | F    | F   | F  | Recalcular únicamente el EDA.                                   |
| F   | F   | F   | T    | T   | T  | Rehacer Features, modelado y forecast desde Gold persistido.    |
| F   | F   | F   | F    | T   | T  | Repetir modelado y forecast desde Features persistidas.         |
| F   | F   | F   | F    | F   | T  | Generar únicamente un nuevo forecast con artefactos existentes. |

### 3.9 Validaciones de coherencia

El configurador bloquea combinaciones que podrían mezclar artefactos de versiones diferentes. En particular:

- no se permite generar Bronze nuevo y saltar directamente a etapas basadas en Silver/Gold antiguos;
- no se permite reconstruir Silver/Gold y después modelar con Features antiguas;
- no se permite reconstruir Features y ejecutar un forecast con un mapping/modelo anterior.

Estas validaciones forman parte de la garantía de consistencia del pipeline.

## 4. Fuentes, rutas y opciones generales

### 4.1 Rutas principales

La configuración estándar define:

```
PROJECT_ROOT = Path(__file__).resolve().parent

RAW_DIR = PROJECT_ROOT / 'data' / 'raw'
WEEKLY_SALES_DIR = RAW_DIR / 'ventas_semanal'
PDF_TICKETS_DIR = RAW_DIR / 'pdfs'
```

Las rutas de salida Bronze, Silver, Gold, Features y **results/** se derivan automáticamente de PROJECT\_ROOT.

### 4.2 Entradas estructuradas

Si se quiere omitir la ingestión de Raw y proporcionar tablas ya estructuradas:

```
STRUCTURED_INPUT_PATHS = {
    # 'tickets': PROJECT_ROOT / 'external_data' / 'tickets.parquet',
}
```

El parámetro:

```
SOURCE_WHEN_INGEST_DISABLED = 'auto'
```

acepta:

|              |                                                                |
|--------------|----------------------------------------------------------------|
| 'auto'       | Preferir Bronze si existe; si no, usar entradas estructuradas. |
| 'bronze'     | Forzar lectura desde data/bronze/.                             |
| 'structured' | Forzar STRUCTURED_INPUT_PATHS.                                 |

### 4.3 Opciones generales

Cuadro 4.1: Opciones generales de ejecución.

| Parámetro                    | Valor habitual | Descripción                                                                             |
|------------------------------|----------------|-----------------------------------------------------------------------------------------|
| VERBOSE                      | True           | Muestra información de progreso y resultados en consola.                                |
| STRICT_INGESTION             | False          | Si se activa, la ingestión puede detenerse ante una fuente problemática.                |
| RECURSIVE_RAW_SCAN           | False          | Permite búsqueda recursiva general bajo RAW_DIR.                                        |
| FUTURE_WEATHER_FORECAST_PATH | None           | Ruta opcional a una previsión meteorológica disponible antes del horizonte de forecast. |

## 5. Ingestión y capa Bronze

### 5.1 Responsabilidad

`ap_io.py` se ocupa de la lectura técnica de fuentes Excel, CSV y PDF, normalización de columnas y persistencia en Bronze.

La ingestión no debe confundirse con depuración semántica: Bronze pretende mantener una representación próxima a la fuente, pero técnicamente homogénea y trazable.

### 5.2 Outputs

Los datasets se guardan como:

```
data/bronze/<dataset>_raw.parquet
```

Cuando existen incidencias de ingestión se registra:

```
data/bronze/ingestion_errors.csv
```

### 5.3 Nivel de detalle de consola

La función de ingestión admite:

```
console_detail='summary'
```

o:

```
console_detail='detailed'
```

El modo `summary` está orientado a operación normal; el modo `detailed` es apropiado para diagnóstico de parsing y compatibilidad de tipos.



## 6. Depuración y calidad de datos

### 6.1 Principios

La depuración implementada en `ap_depuration.py` es deliberadamente conservadora:

- los duplicados exactos pueden eliminarse;
- las claves obligatorias pueden provocar eliminación si no permiten identificar la observación;
- la imputación automática se restringe a missingness bajo;
- los outliers se marcan por defecto, en lugar de eliminarse;
- reglas físicas y de negocio generan flags de calidad;
- todas las decisiones relevantes quedan documentadas en CSV/JSON.

### 6.2 Configuración de DepurationRules

Cuadro 6.1: Parámetros de depuración configurables.

| Parámetro                                             | Valor base | Efecto                                                                                     |
|-------------------------------------------------------|------------|--------------------------------------------------------------------------------------------|
| <code>drop_exact_duplicates</code>                    | True       | Elimina filas completamente duplicadas.                                                    |
| <code>drop_rows_missing_required_keys</code>          | True       | Elimina observaciones que carecen de las claves imprescindibles definidas para su dataset. |
| <code>strip_string_whitespace</code>                  | True       | Normaliza espacios al comienzo/final de cadenas.                                           |
| <code>auto_impute_low_missingness</code>              | True       | Activa imputación automática únicamente para columnas elegibles con missingness reducida.  |
| <code>max_missing_fraction_for_auto_imputation</code> | 0.05       | Umbral máximo de proporción ausente para imputación automática. 0.05 equivale al 5 %.      |
| <code>numeric_imputation_strategy</code>              | 'median'   | Opciones: 'median', 'mean' o 'none'.                                                       |
| <code>categorical_imputation_strategy</code>          | 'constant' | Opciones: 'constant', 'mode' o 'none'.                                                     |
| <code>categorical_missing_label</code>                | 'UNKNOWN'  | Etiqueta utilizada si la estrategia categórica es constante.                               |

| Parámetro                                            | Valor base | Efecto                                                                            |
|------------------------------------------------------|------------|-----------------------------------------------------------------------------------|
| <code>detect_outliers</code>                         | True       | Activa la detección estadística para variables elegibles.                         |
| <code>outlier_action</code>                          | 'flag'     | 'flag' conserva y marca; 'drop' elimina las filas señaladas.                      |
| <code>iqr_multiplier</code>                          | 1.5        | Multiplicador utilizado en las vallas de Tukey.                                   |
| <code>robust_z_threshold</code>                      | 3.5        | Umbral de z robusto basado en mediana/MAD.                                        |
| <code>min_rows_for_outlier_detection</code>          | 8          | Mínimo de observaciones para activar el detector estadístico.                     |
| <code>min_unique_values_for_outlier_detection</code> | 5          | Mínimo de valores distintos para tratar una variable como adecuada para outliers. |
| <code>large_group_people</code>                      | 8          | Umbral de grupo grande para reglas de calidad en reservas.                        |
| <code>payment_reconciliation_tolerance</code>        | 0.02       | Tolerancia para comprobaciones de conciliación de pagos.                          |
| <code>invoice_reconciliation_tolerance</code>        | 0.02       | Tolerancia para comprobaciones de conciliación de facturas.                       |
| <code>plausible_temperature_min_c</code>             | -60.0      | Límite físico inferior utilizado por las reglas meteorológicas.                   |
| <code>plausible_temperature_max_c</code>             | 60.0       | Límite físico superior utilizado por las reglas meteorológicas.                   |
| <code>save_quality_reports</code>                    | True       | Persiste informes de calidad por dataset.                                         |
| <code>save_figures</code>                            | True       | Genera visualizaciones de missingness y distribuciones.                           |
| <code>save_outlier_details</code>                    | True       | Guarda el detalle fila a fila de outliers cuando existan.                         |
| <code>console_detail</code>                          | 'summary'  | 'summary' reduce el logging; 'detailed' muestra el diagnóstico completo.          |

### Consideración metodológica

Cambiar `outlier_action='drop'` altera materialmente el dataset de entrenamiento y debe justificarse con conocimiento del dominio. En datos hosteleros, valores extremos de ventas, tickets o tamaño de reserva pueden ser observaciones reales.

## 6.3 Cómo modificar la política de missing values

Ejemplo: permitir imputación automática hasta un 10 % y utilizar media para variables numéricas:

```
DEPURATION_RULES = DepurationRules(
    auto_impute_low_missingness=True,
    max_missing_fraction_for_auto_imputation=0.10,
    numeric_imputation_strategy='mean',
```

```
categorical_imputation_strategy='constant',  
categorical_missing_label='UNKNOWN',  
)
```

Para desactivar la imputación estadística:

```
numeric_imputation_strategy='none'  
categorical_imputation_strategy='none'
```

No todas las columnas son candidatas a imputación. Identificadores, fechas, campos de nombre/texto libre y otras variables protegidas se excluyen por diseño.

## 6.4 Cómo modificar la detección de outliers

Una política más tolerante puede elevar ambos umbrales:

```
iqr_multiplier=2.0  
robust_z_threshold=4.5
```

Una política más sensible puede reducirlos. Estas modificaciones cambian la cantidad de observaciones marcadas y deben evaluarse a través de los informes de calidad.

Las variables meteorológicas quedan fuera de la detección estadística genérica por diseño y se validan con reglas físicas/lógicas específicas.

## 6.5 Outputs Silver

Los datasets depurados se encuentran en:

```
data/silver/articulos_silver.parquet  
data/silver/departamentos_silver.parquet  
data/silver/eventos_silver.parquet  
data/silver/facturas_silver.parquet  
data/silver/festivos_silver.parquet  
data/silver/menu_silver.parquet  
data/silver/meteo_diaria_silver.parquet  
data/silver/meteo_horaria_silver.parquet  
data/silver/reservas_silver.parquet  
data/silver/tickets_silver.parquet  
data/silver/tips_silver.parquet  
data/silver/total_articles_silver.parquet  
data/silver/ventas_silver.parquet
```

## 6.6 Informes de calidad

Para cada dataset se generan, según aplicabilidad:

Cuadro 6.2: Artefactos de calidad por dataset.

| Patrón                         | Contenido                                                                                                                 |
|--------------------------------|---------------------------------------------------------------------------------------------------------------------------|
| <dataset>__missingness.csv     | Missing count y missing fraction por columna tras depuración.                                                             |
| <dataset>__quality_flags.csv   | Resumen de flags de calidad activos y número/proporción de filas afectadas.                                               |
| <dataset>__outliers.csv        | Detalle de observaciones señaladas como outliers, si existen y está habilitado.                                           |
| <dataset>__quality_report.json | Informe completo del dataset: filas antes/después, duplicados, claves, imputaciones, outliers, flags y reglas utilizadas. |
| depuration_summary.csv         | Resumen agregado de la depuración de todos los datasets.                                                                  |

Se consultan en:

```
results/depuration_reports/
```

## 6.7 Figuras de calidad

Se consultan en:

```
results/depuration_figures/
```

Los principales patrones son:

Cuadro 6.3: Figuras de depuración.

| Fichero                          | Interpretación                                                                    |
|----------------------------------|-----------------------------------------------------------------------------------|
| <dataset>__missingness.png       | Porcentaje de valores ausentes por columna. Solo se genera si existe missingness. |
| <dataset>__<column>__hist.png    | Histograma de una variable numérica analizada en el bloque de outliers.           |
| <dataset>__<column>__boxplot.png | Boxplot de la variable y número de observaciones marcadas como outlier.           |

## 7. Integración y capa Gold

### 7.1 Objetivo

ap\_integration.py transforma las fuentes Silver en dos tablas maestras:

```
data/gold/tabla_maestra_diaria.parquet
data/gold/tabla_maestra_semanal_articulos.parquet
```

La primera tiene granularidad de día. La segunda conserva la granularidad artículo  $\times$  periodo de reporte.

### 7.2 Configuración de IntegrationRules

Cuadro 7.1: Parámetros de integración.

| Parámetro                                  | Configuración | Efecto                                                                                        |
|--------------------------------------------|---------------|-----------------------------------------------------------------------------------------------|
| build_daily_master                         | True          | Genera la tabla Gold diaria.                                                                  |
| build_weekly_article_master                | True          | Genera la tabla Gold artículo-periodo.                                                        |
| create_continuous_daily_calendar           | True          | Construye calendario diario continuo entre los límites definidos por la fuente ancla.         |
| anchor_daily_calendar_to_business_activity | True          | Evita que fuentes contextuales prolonguen artificialmente el calendario operativo.            |
| fill_missing_activity_counts_with_zero     | True          | Completa ceros estructurales en contadores de actividad cuando procede.                       |
| fill_missing_boolean_context_with_false    | True          | Completa flags contextuales booleanos ausentes con falso cuando la semántica lo permite.      |
| prefer_ticket_revenue                      | True          | Da prioridad a tickets como fuente canónica de facturación diaria frente a fuentes solapadas. |
| keep_invitations                           | False         | Configuración distribuida: excluye filas de invitación de la tabla artículo-periodo.          |

| Parámetro                               | Configuración | Efecto                                                                       |
|-----------------------------------------|---------------|------------------------------------------------------------------------------|
| aggregate_duplicate_article_period_rows | True          | Agrupar duplicados del mismo artículo-periodo conservando una clave estable. |
| save_integration_report                 | True          | Guarda informe JSON de integración.                                          |
| save_column_provenance                  | True          | Guarda trazabilidad de columnas Gold.                                        |
| console_detail                          | 'summary'     | Permite cambiar entre consola resumida y detallada.                          |

## 7.3 Informes

Cuadro 7.2: Informes de integración.

| Fichero                         | Uso                                                             |
|---------------------------------|-----------------------------------------------------------------|
| integration_source_coverage.csv | Cobertura, tamaño y rango temporal de cada fuente Silver.       |
| gold_column_provenance.csv      | Origen y transformación de las columnas integradas en Gold.     |
| integration_report.json         | Resumen estructurado de decisiones y resultados de integración. |

Ruta:

```
results/integration_reports/
```

## 8. Análisis exploratorio de datos

### 8.1 Configuración

EDARules permite controlar el alcance del análisis:

Cuadro 8.1: Parámetros principales del EDA.

| Parámetro                     | Valor base | Descripción                                                        |
|-------------------------------|------------|--------------------------------------------------------------------|
| analyze_silver                | True       | Incluye diagnósticos de fuentes Silver.                            |
| analyze_gold                  | True       | Incluye análisis de tablas maestras Gold.                          |
| clean_previous_outputs        | True       | Limpia outputs EDA anteriores antes de regenerarlos.               |
| save_figures                  | True       | Persiste PNG.                                                      |
| save_tables                   | True       | Persiste CSV.                                                      |
| save_report                   | True       | Persiste JSON.                                                     |
| top_n_categories              | 15         | Número de categorías principales en tablas genéricas.              |
| max_target_correlations       | 25         | Límite de correlaciones mostradas/guardadas para el target diario. |
| rolling_window_days           | 7          | Ventana móvil utilizada en visualizaciones temporales diarias.     |
| article_top_n                 | 20         | Número de artículos principales en rankings EDA.                   |
| analyze_reservations          | True       | Activa EDA específico de reservas.                                 |
| analyze_unique_events         | True       | Activa EDA a nivel de evento único.                                |
| generic_numeric_distributions | False      | Si se activa, genera histogramas genéricos adicionales.            |
| generic_numeric_max_columns   | 8          | Máximo de columnas genéricas por dataset.                          |
| histogram_bins                | 30         | Bins de histogramas genéricos.                                     |
| figure_dpi                    | 150        | Resolución de las figuras.                                         |

### 8.2 Tablas EDA

Ruta:

```
results/eda_tables/
```

Los ficheros principales son:

Cuadro 8.2: Tablas generadas por el EDA.

| Fichero                                 | Contenido                                                         |
|-----------------------------------------|-------------------------------------------------------------------|
| eda_dataset_summary.csv                 | Tamaño, missingness y cobertura temporal por dataset Silver/Gold. |
| eda_column_profile.csv                  | Perfil de columnas y tipos.                                       |
| eda_missingness.csv                     | Missingness consolidado.                                          |
| eda_categorical_frequencies.csv         | Frecuencias de variables categóricas seleccionadas.               |
| gold_daily__weekday_profile.csv         | Perfil del target diario por día de la semana.                    |
| gold_daily__monthly_profile.csv         | Perfil del target diario por mes.                                 |
| gold_daily__target_correlations.csv     | Correlaciones descriptivas con el target diario.                  |
| gold_articles__article_profile.csv      | Perfil agregado por artículo.                                     |
| gold_articles__period_totals.csv        | Totales de demanda por periodo.                                   |
| silver_reservations__status_profile.csv | Distribución/perfil de estados de reservas.                       |
| silver_events__unique_events.csv        | Tabla de eventos únicos tras colapsar filas evento-día.           |

### 8.3 Figuras EDA

Ruta:

```
results/eda_figures/
```

Cuadro 8.3: Figuras principales del EDA.

| Figura                              | Interpretación                                                |
|-------------------------------------|---------------------------------------------------------------|
| gold_daily__target_timeline.png     | Evolución temporal del target diario.                         |
| gold_daily__target_correlations.png | Variables con mayor asociación descriptiva con el target.     |
| gold_daily__weekday_pattern.png     | Patrón del target por día de la semana.                       |
| gold_daily__monthly_pattern.png     | Patrón mensual del target.                                    |
| gold_articles__top_units.png        | Ranking de artículos por unidades históricas.                 |
| gold_articles__pareto_units.png     | Curva acumulada de concentración de unidades por artículo.    |
| gold_articles__period_coverage.png  | Cobertura temporal de los artículos a través de los periodos. |
| gold_articles__period_units.png     | Evolución de unidades agregadas por periodo.                  |



| Figura                                                         | Interpretación                                                                            |
|----------------------------------------------------------------|-------------------------------------------------------------------------------------------|
| <code>silver_reservations__status_distribution.png</code>      | Distribución de estados de reserva.                                                       |
| <code>silver_reservations__lead_time.png</code>                | Distribución del tiempo de antelación de reservas.                                        |
| <code>silver_events__unique_event_duration.png</code>          | Duración de eventos únicos.                                                               |
| <code>silver_events__unique_event_intensity.png</code>         | Distribución de intensidad de eventos únicos.                                             |
| <code>&lt;dataset&gt;__&lt;column&gt;__distribution.png</code> | Distribución numérica genérica, solo si <code>generic_numeric_distributions=True</code> . |

El informe global se encuentra en:

`results/eda_reports/eda_report.json`

## 9. Ingeniería de variables

### 9.1 Objetivo

`ap_features.py` construye las variables utilizadas por el modelado y, de forma paralela, un catálogo que documenta su disponibilidad temporal.

Outputs:

```
data/features/features_daily.parquet
data/features/features_article_period.parquet

results/feature_reports/feature_catalogue.csv
results/feature_reports/feature_report.json
```

### 9.2 Configuración de FeatureRules

Cuadro 9.1: Parámetros de ingeniería de variables.

| Parámetro                                                 | Valor base  | Descripción                                                                |
|-----------------------------------------------------------|-------------|----------------------------------------------------------------------------|
| <code>build_daily_features</code>                         | True        | Genera Features diarias.                                                   |
| <code>build_article_period_features</code>                | True        | Genera Features artículo-periodo.                                          |
| <code>daily_lags</code>                                   | (1,7,14,28) | Lags diarios.                                                              |
| <code>daily_rolling_windows</code>                        | (7,14,28)   | Ventanas móviles diarias.                                                  |
| <code>article_lags</code>                                 | (1,2,4,8)   | Lags de demanda artículo-periodo.                                          |
| <code>article_rolling_windows</code>                      | (4,8)       | Ventanas móviles del artículo.                                             |
| <code>include_calendar_features</code>                    | True        | Añade variables de calendario.                                             |
| <code>include_cyclical_calendar_features</code>           | True        | Añade codificaciones seno/coseno de variables periódicas.                  |
| <code>include_current_known_context</code>                | True        | Conserva contexto conocido en el periodo cuando es temporalmente legítimo. |
| <code>aggregate_daily_context_to_article_period</code>    | True        | Agrega contexto diario al periodo del artículo.                            |
| <code>include_weather_context</code>                      | True        | Genera variables meteorológicas y las cataloga según disponibilidad.       |
| <code>require_complete_article_period_for_training</code> | True        | Excluye de entrenamiento periodos incompletos/no estándar.                 |

| Parámetro                                           | Valor base | Descripción                                                                                |
|-----------------------------------------------------|------------|--------------------------------------------------------------------------------------------|
| <code>exclude_negative_targets_from_training</code> | True       | Excluye targets negativos de entrenamiento.                                                |
| <code>article_min_history_for_regime</code>         | 4          | Observaciones históricas mínimas antes de abandonar <code>cold_start</code> .              |
| <code>article_frequent_threshold</code>             | 0.75       | Umbral de tasa de observación para <code>frequent</code> .                                 |
| <code>article_regular_threshold</code>              | 0.50       | Umbral para <code>regular</code> .                                                         |
| <code>article_intermittent_threshold</code>         | 0.25       | Umbral para <code>intermittent</code> ; por debajo se clasifica como <code>sparse</code> . |

### 9.3 Régimen histórico de demanda

El régimen se calcula únicamente a partir de historia previa:

|                                  |                                                                    |
|----------------------------------|--------------------------------------------------------------------|
| <b><code>cold_start</code></b>   | Menos de cuatro observaciones previas con la configuración actual. |
| <b><code>frequent</code></b>     | Tasa histórica de observación $\geq 0.75$ .                        |
| <b><code>regular</code></b>      | Tasa $\geq 0.50$ y menor que 0.75.                                 |
| <b><code>intermittent</code></b> | Tasa $\geq 0.25$ y menor que 0.50.                                 |
| <b><code>sparse</code></b>       | Tasa menor que 0.25.                                               |

### 9.4 Catálogo de variables

`feature_catalogue.csv` es el artefacto central para auditar la selección de variables. Incluye:

- `dataset`;
- `column`;
- `feature_dtype`;
- `origin`;
- `role`;
- `availability`;
- `safe_default`;
- motivo/explicación de clasificación.

Las disponibilidades más relevantes son:

|                                                       |                                                                                      |
|-------------------------------------------------------|--------------------------------------------------------------------------------------|
| <b><code>known_in_advance</code></b>                  | Disponible antes de comenzar el periodo.                                             |
| <b><code>past_only</code></b>                         | Calculada exclusivamente con información anterior.                                   |
| <b><code>requires_forecast</code></b>                 | Solo sería legítima si existe una previsión disponible en el instante de inferencia. |
| <b><code>requires_prediction_time_snapshot</code></b> | Exige un snapshot histórico equivalente al que existiría en tiempo real.             |

|                            |                                                                    |
|----------------------------|--------------------------------------------------------------------|
| <b>same_period_outcome</b> | Resultado del mismo periodo; no debe usarse como predictor causal. |
| <b>target</b>              | Variable objetivo.                                                 |
| <b>unknown</b>             | Disponibilidad no demostrada.                                      |

#### Principio de selección

La generación de una columna y su utilización por el modelo son decisiones separadas. Una variable puede conservarse en la tabla de Features para análisis o trazabilidad y estar marcada como **safe\_default=False**, por lo que no entrará en el modelado estándar.

## 10. Selección de variables para modelado

### 10.1 Proceso

La selección se realiza en dos niveles.

#### 10.1.1 Nivel 1: seguridad temporal

Con la configuración estándar:

```
use_safe_default_features_only=True
```

solo se consideran filas de `feature_catalogue.csv` con:

```
safe_default = True
```

Esto evita que el modelo seleccione automáticamente targets, outcomes del mismo periodo, meteorología que requeriría forecast, snapshots de reservas no reproducibles o metadatos de disponibilidad incierta.

#### 10.1.2 Nivel 2: calidad dentro de Development

El holdout final no participa en el filtrado. Sobre Development se eliminan:

- variables completamente ausentes si `drop_all_missing_features=True`;
- variables con missingness superior a `max_development_missing_fraction`;
- variables constantes si `drop_constant_features=True`.

La configuración actual utiliza:

```
drop_all_missing_features=True  
drop_constant_features=True  
max_development_missing_fraction=0.98
```

### 10.2 Tratamiento de variables numéricas y categóricas

Las variables numéricas se imputan con la mediana aprendida exclusivamente sobre el fold de entrenamiento.

Las variables categóricas:

- representan missingness mediante una categoría explícita;

- se codifican con One-Hot Encoding;
- utilizan `handle_unknown='ignore'` para categorías no vistas en train.

El preprocesador se ajusta dentro de cada fold; no aprende estadísticas de validation ni test.

## 10.3 Auditoría de la selección

Consultar:

```
results/modeling_tables/feature_selection.csv
```

Las columnas principales son:

- `column;`
- `feature_dtype;`
- `role;`
- `availability;`
- `missing_fraction_development;`
- `unique_non_null_development;`
- `selected_for_modeling;`
- `selection_reason.`

### Consideración metodológica

No se recomienda desactivar globalmente `use_safe_default_features_only`. Hacerlo permite que entren en el conjunto candidato columnas que el catálogo ha marcado expresamente como no seguras. Si se desea incorporar una nueva variable, debe justificarse su disponibilidad temporal y actualizarse su clasificación en la ingeniería de Features.

## 11. Modelos implementados y validación

### 11.1 Target

El modelado se ejecuta por defecto sobre:

```
dataset = features_article_period
target  = units
```

El target representa unidades de artículo por periodo de reporte.

### 11.2 Separación temporal

El proceso utiliza:

- Development para selección y comparación;
- holdout final temporal aislado;
- validación cruzada expansiva dentro de Development.

Parámetros principales:

Cuadro 11.1: Configuración temporal del modelado.

| Parámetro                 | Valor base | Descripción                                                      |
|---------------------------|------------|------------------------------------------------------------------|
| final_test_fraction       | 0.15       | Fracción aproximada de periodos reservada al test final.         |
| min_final_test_periods    | 2          | Mínimo de periodos en holdout.                                   |
| cv_splits                 | 4          | Número de folds temporales.                                      |
| cv_validation_fraction    | 0.10       | Fracción de periodos usada para estimar el tamaño de validation. |
| min_cv_validation_periods | 1          | Mínimo de periodos de validation por fold.                       |
| min_train_periods         | 8          | Mínimo de periodos de entrenamiento.                             |
| nonnegative_predictions   | True       | Evita predicciones negativas de unidades.                        |
| top_k                     | 20         | Tamaño del conjunto usado en métricas Top-K.                     |

## 11.3 Baselines causales

Se implementan tres referencias:

1. **Naive lag 1**: utiliza la demanda del periodo inmediatamente anterior.
2. **Rolling mean**: utiliza la media móvil histórica más corta disponible, actualmente 4 periodos.
3. **Historical expanding mean**: media histórica acumulada disponible antes del periodo objetivo.

Cuando una fila no dispone de historia suficiente, puede utilizarse la mediana del target calculada exclusivamente sobre el conjunto train del fold:

```
baseline_train_median_fallback=True
```

## 11.4 HistGradientBoosting Poisson

Modelo:

```
sklearn.ensemble.HistGradientBoostingRegressor  
loss = poisson
```

La pérdida Poisson es adecuada para un target de conteos no negativos. La configuración distribuida es:

```
hgb_learning_rate=0.05  
hgb_max_iter=250  
hgb_max_leaf_nodes=31  
hgb_min_samples_leaf=20  
hgb_l2_regularization=1.0
```

El modelo utiliza:

```
early_stopping=False
```

para evitar que scikit-learn cree internamente una partición aleatoria de validación que rompa el diseño temporal del experimento.

## 11.5 Random Forest

Modelo:

```
sklearn.ensemble.RandomForestRegressor  
criterion = squared_error
```

Configuración:

```
rf_n_estimators=300  
rf_min_samples_leaf=2  
rf_max_features='sqrt'  
rf_max_depth=None  
rf_n_jobs=-1  
random_state=42
```



## 11.6 Selector adaptativo por régimen

Además de los modelos individuales, el sistema implementa un selector adaptativo.

Para cada fold temporal, el modelo utilizado en cada régimen de demanda se elige únicamente a partir de evidencia out-of-fold obtenida en folds anteriores.

Parámetros:

```
run_adaptive_regime_selector=True
adaptive_min_prior_regime_rows=20
adaptive_min_prior_global_rows=50
adaptive_initial_baseline_kind='expanding'
```

La jerarquía de decisión es:

1. evidencia OOF previa suficiente para el régimen;
2. si no existe, evidencia OOF global previa;
3. si aún no existe evidencia, baseline causal inicial predefinido.

Antes de abrir el holdout final se construye:

```
results/modeling_tables/frozen_adaptive_mapping.csv
```

Este mapping asigna a cada régimen un modelo y queda congelado para la evaluación final y el forecast operativo.

## 11.7 Métricas

Las métricas principales son:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$WAPE = \frac{\sum_i |y_i - \hat{y}_i|}{\sum_i |y_i|}$$

$$Bias = \frac{\sum_i (\hat{y}_i - y_i)}{\sum_i y_i}$$

También se calcula solapamiento Top-K para evaluar la capacidad de recuperar los artículos de mayor demanda.

## 11.8 Apertura del holdout final

El parámetro:

```
evaluate_final_test=True
```

está activado en la configuración distribuida porque el experimento del TFM ya ha sido cerrado y el holdout ya se abrió formalmente.

#### Consideración metodológica

En un desarrollo nuevo, `evaluate_final_test` debe mantenerse en **False** hasta congelar la decisión basada en Development. El rendimiento de modelos alternativos en el test final puede documentarse como diagnóstico, pero no debe utilizarse para re-seleccionar el modelo primario.

## 12. Outputs del modelado

### 12.1 Tablas de modelado

Ruta:

```
results/modeling_tables/
```

Cuadro 12.1: Tablas persistidas por `ap_modeling.py`.

| Fichero                                     | Contenido                                                                   |
|---------------------------------------------|-----------------------------------------------------------------------------|
| <code>split_manifest.csv</code>             | Asignación de periodos/filas a Development y final test.                    |
| <code>cv_manifest.csv</code>                | Definición de los folds temporales train/validation.                        |
| <code>feature_selection.csv</code>          | Auditoría de selección final de predictores.                                |
| <code>cv_baseline_metrics.csv</code>        | Métricas de baselines por fold.                                             |
| <code>cv_baseline_summary.csv</code>        | Resumen agregado de baselines.                                              |
| <code>cv_regime_metrics.csv</code>          | Métricas de baselines desglosadas por régimen.                              |
| <code>cv_period_metrics.csv</code>          | Métricas de baselines desglosadas por periodo.                              |
| <code>cv_ml_metrics.csv</code>              | Métricas de los candidatos de Machine Learning por fold.                    |
| <code>cv_ml_summary.csv</code>              | Resumen agregado de modelos ML.                                             |
| <code>cv_ml_regime_metrics.csv</code>       | Resultados ML por régimen.                                                  |
| <code>cv_ml_period_metrics.csv</code>       | Resultados ML por periodo.                                                  |
| <code>cv_adaptive_metrics.csv</code>        | Métricas del selector adaptativo por fold.                                  |
| <code>cv_adaptive_summary.csv</code>        | Resumen del selector adaptativo.                                            |
| <code>cv_adaptive_regime_metrics.csv</code> | Resultados adaptativos por régimen.                                         |
| <code>cv_adaptive_period_metrics.csv</code> | Resultados adaptativos por periodo.                                         |
| <code>cv_adaptive_selection.csv</code>      | Decisión causal de modelo utilizada por régimen/fold y fuente de evidencia. |
| <code>cv_model_metrics.csv</code>           | Métricas consolidadas de todos los competidores.                            |
| <code>cv_model_summary.csv</code>           | Leaderboard de Development utilizado para selección.                        |
| <code>frozen_adaptive_mapping.csv</code>    | Mapping final régimen → modelo congelado con Development OOF.               |

| Fichero                       | Contenido                                                             |
|-------------------------------|-----------------------------------------------------------------------|
| final_test_metrics.csv        | Métricas del holdout final si <code>evaluate_final_test=True</code> . |
| final_test_regime_metrics.csv | Diagnóstico del holdout por régimen.                                  |
| final_test_period_metrics.csv | Diagnóstico del holdout por periodo.                                  |

## 12.2 Predicciones de evaluación

Ruta:

```
results/modeling_predictions/
```

Cuadro 12.2: Predicciones persistidas durante la evaluación.

| Fichero                         | Contenido                                         |
|---------------------------------|---------------------------------------------------|
| cv_baseline_predictions.parquet | Predicciones out-of-fold de baselines.            |
| cv_ml_predictions.parquet       | Predicciones out-of-fold de modelos ML.           |
| cv_adaptive_predictions.parquet | Predicciones out-of-fold del selector adaptativo. |
| final_test_predictions.parquet  | Predicciones del holdout final, si se evalúa.     |

## 12.3 Informe JSON

```
results/modeling_reports/modeling_development_report.json
```

Incluye reglas utilizadas, variables, split, leaderboard, baselines, mapping adaptativo, resultados finales y notas metodológicas.

## 13. Contexto futuro

### 13.1 Información admitida

`ap_future_context.py` construye una fila diaria para cada día del horizonte futuro utilizando información conocida antes del periodo.

Puede incorporar:

- eventos programados;
- festivos;
- previsión meteorológica proporcionada explícitamente.

La meteorología observada posteriormente no se utiliza como sustituto de una previsión histórica.

### 13.2 Configuración

```
FUTURE_CONTEXT_RULES = FutureContextRules(  
    include_events=True,  
    include_holidays=True,  
    include_weather_forecast=True,  
    save_tables=True,  
    save_report=True,  
)
```

El fichero meteorológico opcional puede proporcionarse mediante:

```
FUTURE_WEATHER_FORECAST_PATH = Path('...')
```

El orquestador admite CSV, Parquet y Excel para esta fuente.

### 13.3 Outputs

```
results/future_context_tables/future_daily_context.csv  
results/future_context_tables/future_events_expanded.csv  
results/future_context_tables/future_holidays.csv  
results/future_context_reports/future_context_report.json
```

`future_daily_context.csv` es el dataset principal que se inyecta en la construcción de Features del siguiente periodo.

## 14. Universo de artículos

### 14.1 Objetivo

`ap_article_scope.py` separa dos problemas:

1. predecir la demanda de un artículo;
2. decidir si ese artículo debe recibir forecast.

La ausencia de un artículo en periodos recientes no se interpreta automáticamente como producto retirado.

### 14.2 Políticas

El parámetro:

```
policy='conservative_observed_history'
```

mantiene forecastables los artículos con historia observada salvo que exista una señal explícita incompatible.

También existe:

```
policy='recent_or_explicit'
```

que exige una evidencia más reciente o explícita.

La política conservadora es la configuración del proyecto porque no existe en las fuentes actuales una señal autoritativa de activo/inactivo.

### 14.3 Parámetros principales

Cuadro 14.1: Configuración del scope de artículos.

| Parámetro                         | Valor base | Descripción                                  |
|-----------------------------------|------------|----------------------------------------------|
| <code>recent_periods_short</code> | 4          | Ventana de actividad reciente.               |
| <code>recent_periods_long</code>  | 8          | Ventana de actividad moderadamente reciente. |

| Parámetro                                | Valor base                              | Descripción                                                                                 |
|------------------------------------------|-----------------------------------------|---------------------------------------------------------------------------------------------|
| menu_informative_max_<br>master_coverage | 0.95                                    | Si el menú contiene menos del 95 % del maestro, puede actuar como señal de catálogo actual. |
| policy                                   | 'conservative_<br>observed_<br>history' | Política de inclusión.                                                                      |

## 14.4 Outputs

```
results/article_scope_tables/article_scope_audit.csv  
results/article_scope_tables/article_scope_eligible.csv  
results/article_scope_tables/article_scope_summary.csv  
results/article_scope_reports/article_scope_report.json
```

article\_scope\_audit.csv es el fichero principal para revisar:

- pertenencia a maestro/carta;
- actividad reciente;
- último periodo observado;
- estado de actividad;
- señales explícitas de activo/inactivo;
- necesidad de revisión manual;
- recomendación de elegibilidad.

## 15. Forecast operacional

### 15.1 Proceso de despliegue

Una vez cerrado el experimento, `ap_operational.py`:

1. infiere la cadencia histórica de periodos completos;
2. alinea el siguiente periodo completo;
3. excluye periodos parciales del historial usado para lags/rolling;
4. reconstruye Features futuras con el mismo motor de Features;
5. aplica el scope de artículos;
6. utiliza exactamente el conjunto congelado de predictores;
7. reajusta los candidatos necesarios con todo el histórico elegible;
8. aplica el mapping congelado por régimen;
9. fuerza no negatividad;
10. genera ranking y clasificación ABC.

El refit de despliegue puede utilizar todo el histórico conocido una vez finalizada la evaluación, incluido el antiguo holdout. Lo que permanece congelado es la arquitectura/criterio de selección.

### 15.2 Configuración

Cuadro 15.1: Parámetros operacionales.

| Parámetro                              | Valor                       | Descripción                                                                           |
|----------------------------------------|-----------------------------|---------------------------------------------------------------------------------------|
| <code>expected_period_days</code>      | <code>None</code>           | Si es <code>None</code> , la cadencia se infiere del histórico completo.              |
| <code>article_scope</code>             | <code>'all_observed'</code> | Construye scaffold para todos los artículos observados antes de aplicar la auditoría. |
| <code>round_prediction_to_units</code> | <code>True</code>           | Añade unidades enteras redondeadas.                                                   |
| <code>abc_threshold_a</code>           | <code>0.80</code>           | Umbral acumulado para clase A.                                                        |
| <code>abc_threshold_b</code>           | <code>0.95</code>           | Umbral acumulado para clase B; el resto es C.                                         |



| Parámetro              | Valor                        | Descripción                                             |
|------------------------|------------------------------|---------------------------------------------------------|
| default_fallback_model | Historical<br>expanding mean | Fallback operacional si no existe selección específica. |

article\_scope también admite 'latest\_period\_observed', pero no se recomienda utilizarlo sin revisar la semántica de disponibilidad: un último periodo parcial o una demanda intermitente podría excluir artículos válidos.

## 15.3 Outputs

Ruta:

```
results/operational_forecasts/
```

Cuadro 15.2: Outputs operacionales.

| Fichero                          | Contenido                                                            |
|----------------------------------|----------------------------------------------------------------------|
| next_period_article_forecast.csv | Predicción completa por artículo; es la salida operativa principal.  |
| next_period_forecast_summary.csv | Resumen del horizonte, número de artículos y volumen total previsto. |
| next_period_model_usage.csv      | Número de artículos asignados a cada modelo.                         |
| next_period_regime_usage.csv     | Distribución de artículos por régimen de demanda.                    |

Informe estructurado:

```
results/operational_reports/operational_forecast_report.json
```

## 15.4 Columnas principales del forecast

En next\_period\_article\_forecast.csv deben revisarse especialmente:

Cuadro 15.3: Campos principales de la salida operacional.

| Campo                       | Significado                                          |
|-----------------------------|------------------------------------------------------|
| article_code                | Identificador del artículo.                          |
| article_name                | Nombre/descripción del artículo.                     |
| article_demand_regime_prior | Régimen calculado usando solo historia previa.       |
| selected_model              | Modelo aplicado según el mapping congelado.          |
| predicted_units             | Predicción continua.                                 |
| predicted_units_rounded     | Predicción redondeada para interpretación operativa. |

| Campo                     | Significado                                                              |
|---------------------------|--------------------------------------------------------------------------|
| forecast_rank             | Ranking descendente de demanda prevista.                                 |
| forecast_share            | Participación estimada del artículo en el total previsto.                |
| forecast_cumulative_share | Participación acumulada utilizada por ABC.                               |
| planning_class            | Clase A/B/C de priorización.                                             |
| activity_status           | Estado de actividad según auditoría.                                     |
| manual_review_required    | Flag para revisión humana del scope.                                     |
| forecast_scope_reason     | Razón por la que el artículo se incluye/excluye en la política de scope. |

#### Alcance de la salida

La predicción se expresa en unidades de artículo. La traducción a necesidades de compra de ingredientes requiere un dataset adicional artículo → receta/BOM con cantidades de ingrediente por unidad.

## 16. Catálogo global de outputs

### 16.1 Dónde consultar cada tipo de resultado

Cuadro 16.1: Mapa de resultados del repositorio.

| Necesidad              | Ruta                           | Artefactos clave                                               |
|------------------------|--------------------------------|----------------------------------------------------------------|
| Datos ingeridos        | data/bronze/                   | Parquet *_raw.parquet.                                         |
| Datos depurados        | data/silver/                   | Parquet *_silver.parquet.                                      |
| Diagnóstico de calidad | results/depuration_reports/    | Missingness, flags, outliers, JSON.                            |
| Gráficas de calidad    | results/depuration_figures/    | Missingness, histogramas, boxplots.                            |
| Tablas maestras        | data/gold/                     | Daily Gold y article-period Gold.                              |
| Trazabilidad Gold      | results/integration_reports/   | Coverage, provenance, report.                                  |
| Análisis exploratorio  | results/eda_tables/            | Perfiles y tablas diagnósticas.                                |
| Gráficas EDA           | results/eda_figures/           | Patrones temporales, Pareto, cobertura, reservas y eventos.    |
| Features               | data/features/                 | Tablas Daily y Article-period.                                 |
| Auditoría de variables | results/feature_reports/       | feature_catalogue.csv, feature_report.json.                    |
| Selección/modelos      | results/modeling_tables/       | Leaderboard, feature selection, frozen mapping, final metrics. |
| Predicciones CV/test   | results/modeling_predictions/  | Parquet con predicciones individuales.                         |
| Metodología modelado   | results/modeling_reports/      | modeling_development_report.json.                              |
| Contexto futuro        | results/future_context_tables/ | Contexto diario, eventos, festivos.                            |
| Scope de artículos     | results/article_scope_tables/  | Audit, eligible, summary.                                      |
| Forecast final         | results/operational_forecasts/ | Predicción por artículo y resúmenes.                           |

| <b>Necesidad</b>    | <b>Ruta</b>                      | <b>Artefactos clave</b> |
|---------------------|----------------------------------|-------------------------|
| Informe operacional | results/operational_<br>reports/ | JSON del forecast.      |

## 17. Procedimientos de uso

### 17.1 Reconstrucción completa

```
DO_INGEST = True
DO_DEPURATION = True
DO_EDA = True
DO_FEATURES = True
DO_MODELING = True
DO_OPERATIONAL = True
```

Utilizar cuando cambien las fuentes originales o se quiera reproducir el pipeline completo.

### 17.2 Recalcular únicamente el EDA

```
DO_INGEST = False
DO_DEPURATION = False
DO_EDA = True
DO_FEATURES = False
DO_MODELING = False
DO_OPERATIONAL = False
```

Requiere Silver/Gold persistidos.

### 17.3 Rehacer Features, modelado y forecast

```
DO_INGEST = False
DO_DEPURATION = False
DO_EDA = False
DO_FEATURES = True
DO_MODELING = True
DO_OPERATIONAL = True
```

Útil tras modificar reglas de Features manteniendo Gold.

### 17.4 Repetir el experimento de modelado

```
DO_INGEST = False
DO_DEPURATION = False
DO_EDA = False
```

```
DO_FEATURES = False
DO_MODELING = True
DO_OPERATIONAL = False
```

## 17.5 Generar solo el siguiente forecast

```
DO_INGEST = False
DO_DEPURATION = False
DO_EDA = False
DO_FEATURES = False
DO_MODELING = False
DO_OPERATIONAL = True
```

Este modo reutiliza Silver, Gold, Features y artefactos congelados de modelado, y vuelve a construir el contexto futuro, el scope y la predicción operacional.

## 18. Personalización controlada

### 18.1 Cambiar criterios de depuración

Las modificaciones habituales deben realizarse en `DEPURATION_RULES`, no editando funciones internas.

Ejemplos:

#### 18.1.1 Aumentar el umbral de imputación

```
max_missing_fraction_for_auto_imputation=0.10
```

#### 18.1.2 No imputar variables numéricas

```
numeric_imputation_strategy='none'
```

#### 18.1.3 Hacer más conservadora la detección de outliers

```
iqr_multiplier=2.0  
robust_z_threshold=4.5
```

#### 18.1.4 Eliminar outliers

```
outlier_action='drop'
```

Esta última modificación requiere una justificación explícita y debe revisarse con los CSV/plots de calidad antes de utilizarse para modelado.

### 18.2 Cambiar lags y ventanas

Ejemplo:

```
FEATURE_RULES = FeatureRules(  
    article_lags=(1, 2, 4, 8, 12),  
    article_rolling_windows=(4, 8, 12),  
)
```

Al modificar Features debe volver a ejecutarse modelado antes de generar un forecast.

## 18.3 Cambiar el holdout o CV

Ejemplo:

```
MODELING_RULES = ModelingRules(  
    final_test_fraction=0.20,  
    cv_splits=5,  
    min_train_periods=10,  
)
```

Cambiar la partición invalida la comparabilidad directa con los resultados anteriores y debe considerarse un nuevo experimento.

## 18.4 Cambiar hiperparámetros

Ejemplo:

```
MODELING_RULES = ModelingRules(  
    hgb_learning_rate=0.03,  
    hgb_max_iter=400,  
    rf_n_estimators=500,  
    rf_min_samples_leaf=3,  
)
```

Los hiperparámetros deben compararse únicamente dentro de Development. No deben ajustarse después de observar el holdout final.

## 18.5 Cambiar la política de scope

Ejemplo más restrictivo:

```
ARTICLE_SCOPE_RULES = ArticleScopeRules(  
    recent_periods_short=4,  
    recent_periods_long=8,  
    policy='recent_or_explicit',  
)
```

Debe revisarse `article_scope_audit.csv` para comprobar qué artículos se excluirían antes de adoptar esta política en operación.



## 19. Interpretación de warnings y problemas frecuentes

### 19.1 Periodo histórico incompleto

Si aparece un warning indicando que el último periodo es incompleto, el comportamiento esperado es:

- el periodo parcial se conserva para auditoría;
- no se utiliza como periodo completo en lags/rolling de despliegue;
- el forecast se alinea con el siguiente periodo estándar completo.

### 19.2 Sin previsión meteorológica

No constituye un error. El contexto de eventos/festivos puede estar completo mientras las variables que requieren forecast meteorológico permanecen no disponibles.

### 19.3 Muchos outliers

La detección estadística no implica que los datos sean erróneos. Deben consultarse:

```
results/depuration_reports/<dataset>__outliers.csv  
results/depuration_figures/<dataset>__<column>__hist.png  
results/depuration_figures/<dataset>__<column>__boxplot.png
```

antes de cambiar la política.

### 19.4 Falta una capa persistida

Si se desactiva una etapa upstream, el pipeline espera encontrar los artefactos correspondientes en disco. Por ejemplo:

- `DO_FEATURES=False` + `DO_MODELING=True` requiere Features persistidas;
- `DO_MODELING=False` + `DO_OPERATIONAL=True` requiere `feature_selection.csv`, `frozen_adaptive_mapping.csv` y el informe de modelado.

## 20. Reproducibilidad y trazabilidad

### 20.1 Principios

La reproducibilidad se apoya en:

- capas persistidas Bronze/Silver/Gold/Features;
- configuración explícita mediante dataclasses `*Rules`;
- `random_state=42` en modelos estocásticos;
- manifiestos de splits y folds;
- catálogo de variables;
- mapping adaptativo congelado;
- informes JSON con reglas utilizadas;
- predicciones OOF y de test persistidas.

### 20.2 Artefactos mínimos para auditar una ejecución

Para una auditoría completa del experimento predictivo, conservar:

```
results/feature_reports/feature_catalogue.csv
results/modeling_tables/split_manifest.csv
results/modeling_tables/cv_manifest.csv
results/modeling_tables/feature_selection.csv
results/modeling_tables/cv_model_summary.csv
results/modeling_tables/frozen_adaptive_mapping.csv
results/modeling_tables/final_test_metrics.csv
results/modeling_reports/modeling_development_report.json
```

Para la decisión operacional conservar además:

```
results/future_context_tables/future_daily_context.csv
results/article_scope_tables/article_scope_audit.csv
results/operational_forecasts/next_period_article_forecast.csv
results/operational_reports/operational_forecast_report.json
```

## A. Referencia rápida de configuración

### A.1 Configuración estándar

```
# Pipeline
DO_INGEST = True
DO_DEPURATION = True
DO_EDA = True
DO_FEATURES = True
DO_MODELING = True
DO_OPERATIONAL = True

# Context
FUTURE_WEATHER_FORECAST_PATH = None

# Input source when ingestion is disabled
STRUCTURED_INPUT_PATHS = {}
SOURCE_WHEN_INGEST_DISABLED = 'auto'

# Runtime
VERBOSE = True
STRICT_INGESTION = False
RECURSIVE_RAW_SCAN = False
```

### A.2 Checklist previo a una ejecución completa

1. Activar el entorno virtual.
2. Verificar `requirements.txt`.
3. Confirmar la presencia de las fuentes en `data/raw/`.
4. Revisar los seis flags.
5. Revisar si existe un forecast meteorológico válido.
6. Revisar cualquier modificación de `*Rules`.
7. Ejecutar `pythonanalysis_prediction.py`.
8. Comprobar warnings.
9. Consultar los artefactos persistidos en `results/`.

### A.3 Orden recomendado de consulta de resultados

Después de una ejecución completa:

1. `results/depuration_reports/depuration_summary.csv` para calidad global.
2. `results/integration_reports/integration_source_coverage.csv` para cobertura de fuentes.
3. `results/eda_figures/` y `results/eda_tables/` para estructura descriptiva.
4. `results/feature_reports/feature_catalogue.csv` para disponibilidad y leakage.
5. `results/modeling_tables/feature_selection.csv` para predictores finales.
6. `results/modeling_tables/cv_model_summary.csv` para comparación de modelos.
7. `results/modeling_tables/frozen_adaptive_mapping.csv` para la regla de selección por régimen.
8. `results/modeling_tables/final_test_metrics.csv` para evaluación final.
9. `results/future_context_tables/future_daily_context.csv` para contexto del horizonte.
10. `results/article_scope_tables/article_scope_audit.csv` para elegibilidad de artículos.
11. `results/operational_forecasts/next_period_article_forecast.csv` como resultado operativo principal.

## B. Resumen de interfaz pública

La interfaz de operación se compone de tres niveles:

1. **Flags de ejecución:** deciden qué etapas se recalculan.
2. **Rutas y opciones generales:** definen fuentes, modo de carga y logging.
3. **Objetos \*Rules:** parametrizan la lógica de calidad, integración, EDA, Features, modelado, contexto, scope y forecast.

Los módulos de `src/` implementan el comportamiento interno. La modificación normal del sistema debe realizarse primero a través de estos puntos de configuración. Las salidas persistidas permiten auditar cada decisión sin depender exclusivamente de la consola.